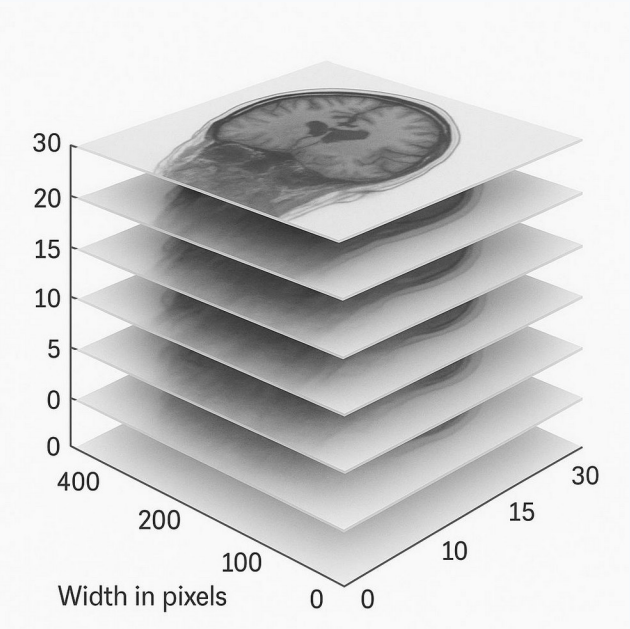
nnU-Net v2 | 三维医学影像分割

技术原理 · 数据预处理 · 自动规划 · 训练机制

从空间采样到自动规划
从 Patch 训练到多尺度监督



重点：解释数据如何变成网络输入

覆盖完整流程，实验配置集中在一页

数据准备 → Fingerprint → Planning → Preprocessing → Training → Validation

01 完整 Pipeline

Fingerprint 负责统计； Planner 决定配置； Preprocessor 执行变换； Trainer 学习权重。

准备数据

影像 / 标签

dataset.json

Fingerprint

Spacing / Shape

强度统计

Plans

间距 / Patch

拓扑 / Batch

Preprocess

转置 / 裁剪

归一化 / 重采样

动态取 Patch

随机 / 前景引导

增强与训练

空间变换 / Loss / 更新

完整验证

滑窗 / 空间恢复 / 指标

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

02 数据转换与质控：从独立 Mask 到多类别标签

文件尺寸一致只是必要检查之一；还必须检查方向、间距、位置与类别语义。

```
Dataset001_Example/
  imagesTr/case001_0000.nii.gz
  imagesTr/case001_0001.nii.gz
  labelsTr/case001.nii.gz
  dataset.json
```

_0000 、 _0001 表示输入通道。

channel_names 决定默认归一化映射。

准备阶段的四项检查

几何： Shape / Spacing / Affine

多通道：同一病例各序列已经对齐

标签：整数类别、背景 0 、无非法值

划分：同一患者不跨训练 / 验证集

框架不会通过 resize 自动修复错位，也不会可靠地从影像内容猜测 CT / MRI 模态。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

03 三维 MRI：多平面观察与切片堆叠

三维影像需要同时理解空间几何与标签语义； Image 、分割标签和有效区 Mask 的处理方式不同。

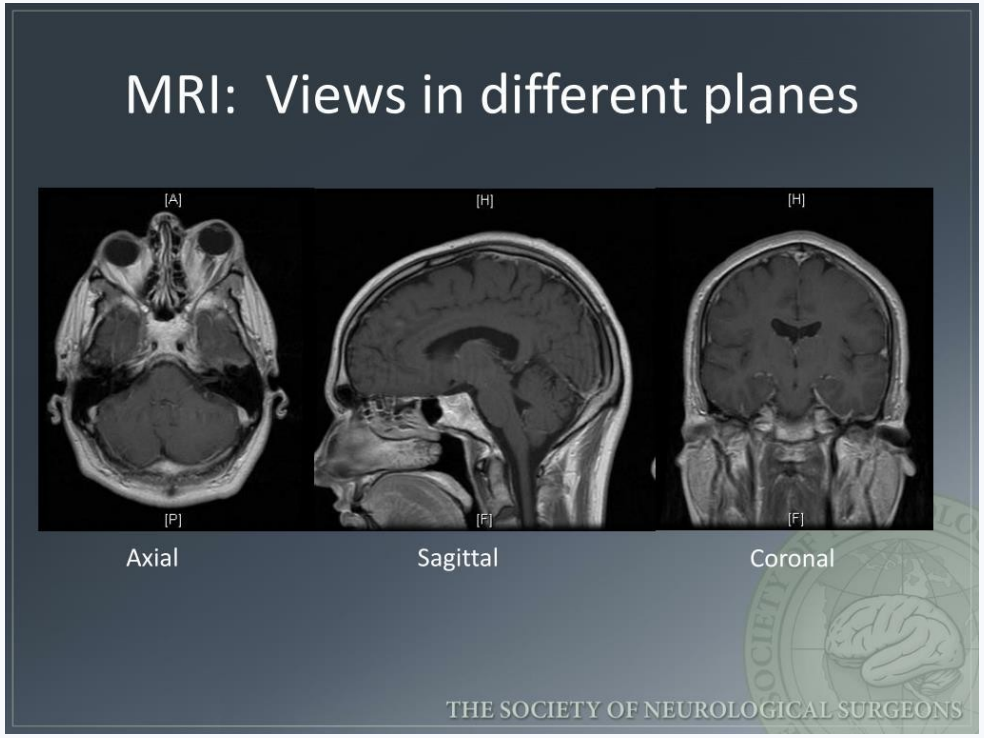


Image 与两种 Mask

Image： 连续强度，归一化和连续插值

标签 Mask： 离散类别，不做 Z-score

有效区 Mask： 控制裁剪或统计区域

Shape： 体素数； Spacing： 物理间距

Affine： 体素坐标 → 世界坐标

图像与标签共享几何变换； MRI 三视图是空间观察示例，不是本实验病例。

04 Dataset Fingerprint → Experiment Planning

默认分析原始间距、非零裁剪后尺寸、裁剪比例与前景强度等；此处不执行目标网格重采样。

各病例读取

Spacing

Shape

有效区裁剪统计

shapes_after_crop

裁剪体积比例

前景强度采样

每通道均值 / 标准差

分位数

数据集摘要

dataset_fingerprint.json

几何统计 → 网络规划

决定目标间距、典型尺寸与训练视野。

强度统计 → 归一化

CT 使用训练集前景统计； MRI 常逐病例计算。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

05 各向异性：处理某个维度层间距太大的问题

每一列独立计算统计量；目标间距不必来自某一个病例，也不要求变成 1×1×1 mm 。

病例	轴 0 (mm)	轴 1 (mm)	轴 2 (mm)
A	1	1	3
B	1	1	5
C	1	1	7
D	1	1	9
E	1	1	11
中位数	1	1	7

厚层轴调整示例

中位 Shape = [256,256,40]

7 > 3×1 ， 且 40×3 < 256

两条件满足 → 该轴取 10% 分位数

[3,5,7,9,11] → P10 = 3.8

目标间距： [1,1,3.8] mm

这是 Planner 的间距规则；执行重采样时是否分轴，还要由重采样器判断。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

06 重采样 Resampling：确定目标网格

各病例共享目标 Spacing，但预处理后的完整 Volume Shape 仍然可以不同。

$$N_{new}[i] = \mathrm{round}(N_{crop}[i] \times S_{old}[i] / S_{target}[i])$$

裁剪后原始数据

Shape [20,256,256]

Spacing [5,1,1]

→

指定目标间距

[2.5,0.5,0.5] mm

三个方向采样均加密

→

目标数组

Shape [40,512,512]

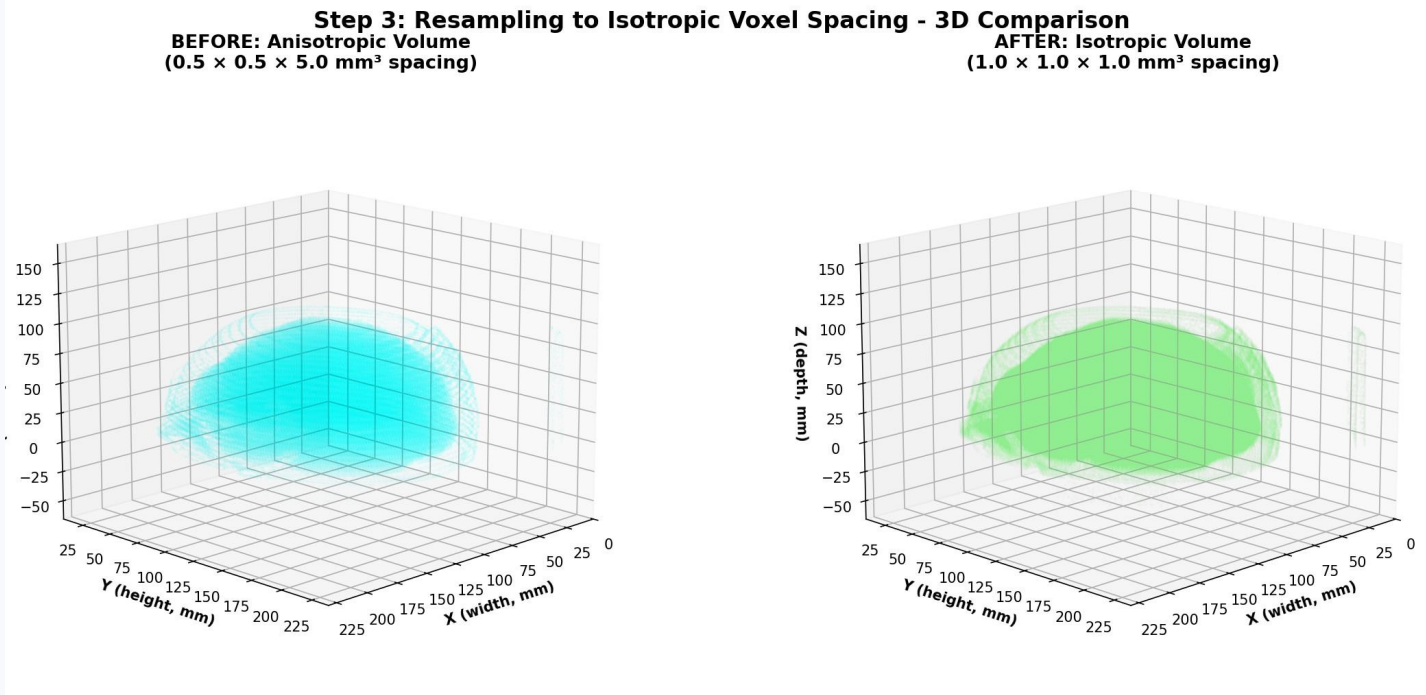
体素总数增加 8 倍

Shape 与 Spacing 必须采用相同轴序；插值新增体素，不增加真正采集到的医学信息。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

07 重采样 Resampling： Separate-Z

先在高分辨率平面内插值，再沿低分辨率轴处理；不是先对 XYZ 插值后再重复处理 Z 。



Separate-Z 的实际顺序

[20,256,256]

↓ 平面内 order

[20,512,512]

↓ 低分辨率轴 order_z

[40,512,512]

右侧 Shape 为独立教学例子；左图采用另一组示例间距。目标 Spacing 不要求各向同性。

按原始 / 目标间距与低分辨率轴条件决定是否分轴；不分轴时直接整体插值。

08 图像与 Mask 的插值方法

order 控制插值阶数；它不是训练超参数，也不是卷积核大小。

order	方法	一维教学例子
0	最近邻	x=0 强度 10， x=1 强度 20； x=0.25 → 10
1	线性插值	x=0.25 → 0.75×10 + 0.25×20 = 12.5
3	三次插值	利用更大邻域；结果还取决于边界约定

```
image: is_seg=False, order=3
label: is_seg=True,  order=1
Separate-Z: order_z=0
```

标签 [1,3] 不能平均成类别 2

按类别二值图插值，再重建离散标签。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

09 CT 与 MRI 的归一化

方案由通道元数据及规划规则确定；不是根据验证成绩动态搜索归一化方法。

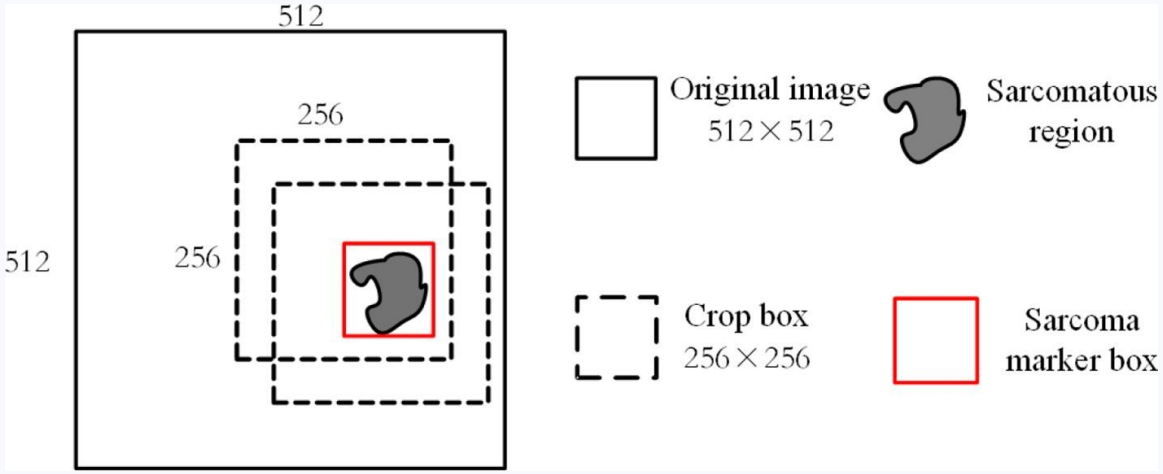
维度	CTNormalization	MRI 常用 ZScoreNormalization
强度基础	HU 通常具有可比较的物理意义	绝对强度随设备、序列、扫描变化
统计范围	整个训练数据集的前景强度样本	当前病例、当前输入通道
强度截断	前景 0.5% ～ 99.5% 分位数	默认不使用同一套 CT 截断
归一化	统一训练集 mean / std	每病例 mean / std
推理	复用训练集统计，无需真值标签	对新病例计算其自身统计

默认流程不自动加入 MRI 偏置场校正或直方图匹配；有效区 Mask 与器官真值 Mask 不同。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

10 裁剪 Cropping 与强度处理

预处理顺序： Transpose → Crop → Normalize → Resample ； 非零区域裁剪不同于前景采样。



图中是前景附近的 Patch 裁剪示意。

非零裁剪例： bbox=[[2,8],[3,10],[1,6]]

image[2:8,3:10,1:6] → Shape [6,7,5]

Z-score 数值例子

输入： [10,20,30,40]

μ=25 ； σ≈11.1803

z=(x−μ)/max(σ,ε)

输出： [-1.342,-0.447,0.447,1.342]

使用有效区 Mask 会改变统计范围

图像与标签采用同一裁剪框

非零掩膜由各通道有效区取并集并填孔；填孔操作作用于掩膜，不修改原始影像强度。

11 基于不同数据集进行自配置

显存目标是估算预算，不是当前 GPU 剩余显存的实时测量。

典型数据尺度

目标 Spacing

重采样后中位 Shape

初始 Patch / 拓扑

物理视野

卷积核 / 下采样

估算资源开销

各级特征图

显存预算

调整并生成 Plans

Patch 可整除性

最小特征图 / Batch

各向异性可能影响早期拓扑

例如 kernel=[1,3,3] 、 stride=[1,2,2] 。

尺度逐渐接近后使用完整 3D 操作

空间尺寸过小时停止相应轴的下采样。

Patch 大小由 Plans 决定；每次训练只动态改变位置，不按当前器官大小临时改变网络输入。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

12 裁剪 Cropping 与前景 Patch 采样

默认确定性模式按 Batch 内的样本索引分配；不是每次独立以 33% 概率抛硬币。

```
threshold = round(B * (1 - p))
force_fg = sample_index >= threshold
```

B=2， p=0.33	索引 0	索引 1
threshold=1	普通随机	强制前景

前景引导路径

先选病例

从现有前景类别中选类别

从该类候选坐标中选一个体素

围绕该体素构造采样框

无可用前景时可退回随机

普通随机 Patch 也可能有器官；强制前景采样比例不等于最终“含前景 Patch” 的比例。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

13 前景 Patch 采样：确定采样框

以下示例采用当前官方上下界约束逻辑，无额外增强 Padding；旧版本右边界处理可能不同。

```
N = [100,120,80]
P = [40,40,32]
allowed_start = [0,0,0] ... [60,80,48]
start = clip(v - P//2, lb, ub)
end = start + P
```

前景坐标 v	起点 start	终点 end
[50,70,30]	[30,50,14]	[70,90,46]
[5,10,4]	[0,0,0]	[40,40,32]
[95,115,75]	[60,80,48]	[100,120,80]

随机采样：从每个轴允许的起点区间抽整数。

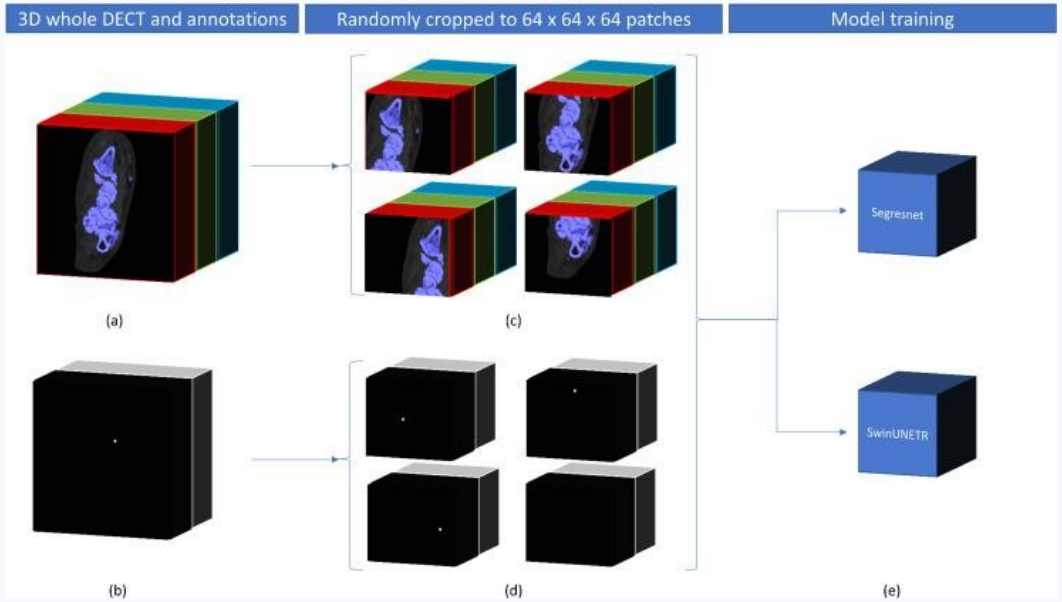
病例小于 Patch：先取框与影像的交集，再对缺失区域显式 Padding。

1D 例：病例长 24、Patch 长 32 → 有效数据 24 + 两侧各补 4；不能用负索引切片替代 Padding。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06。数值小例子均为教学示例。

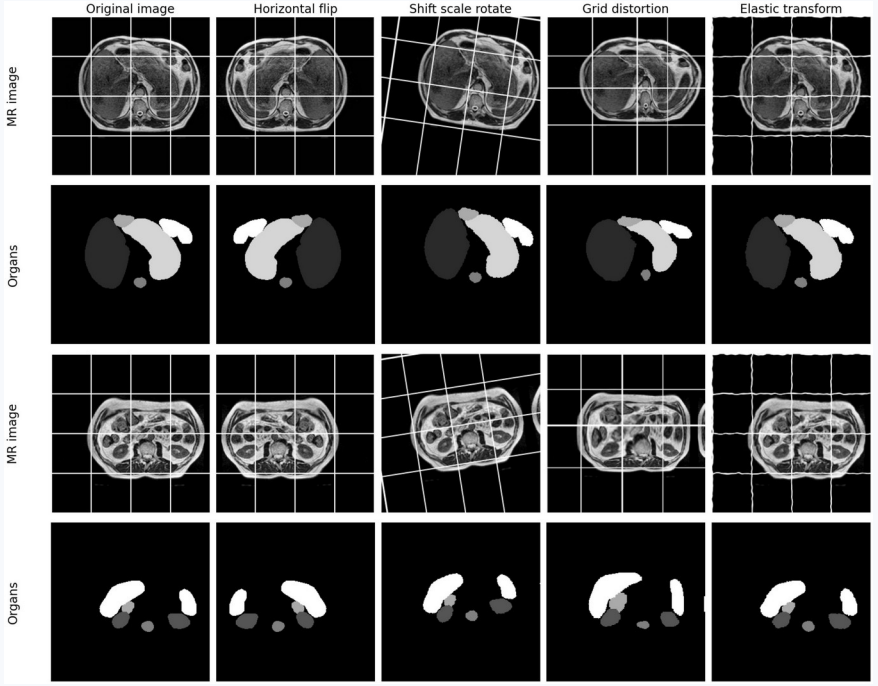
14 基于 Patch 的训练与图像增强示例

先抽取较大初始块，再通过空间增强生成最终网络 Patch ； 空间变换同步作用于图像和标签。



左图为其他任务 / 网络的 Patch 示例。

初始块为旋转和缩放提供额外上下文。

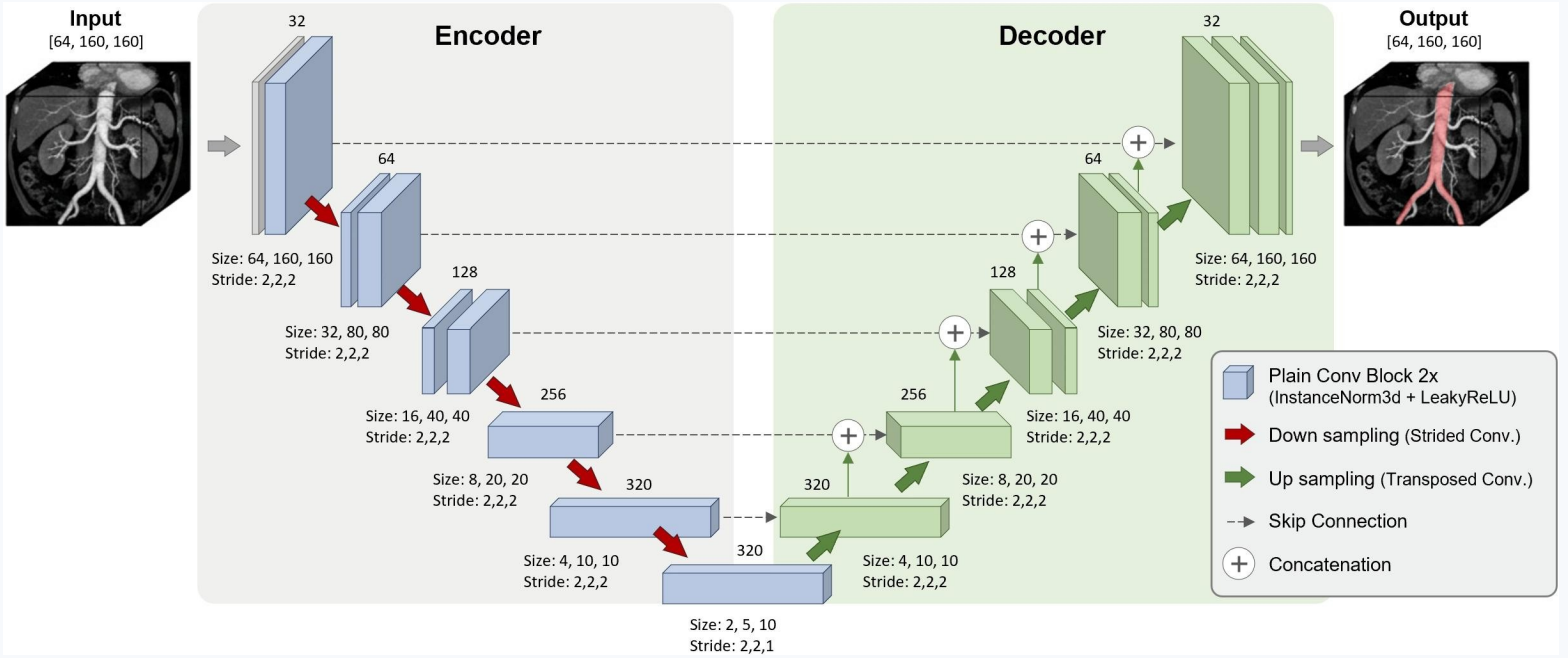


右图为通用增强示例，不是默认启用清单。

P_load → 空间变换 → P_final ； 128^2 旋转 45° 包围框约 181^2 ，但不保证完整器官始终在 Patch 中。

15 3D U-Net 结构图与 ResEnc L

Encoder 提取特征， Decoder 恢复分辨率； U-Net 跨层拼接与残差块内部相加是两种连接。



左图仅说明 U-Net 结构，尺寸 / 步幅标注不是通用配置；实际架构由 Plans 决定。

ResEnc L

Encoder 加入残差块

y=F(x)+S(x)

约 24GB 级别规划预算

重新估算 Patch / Batch

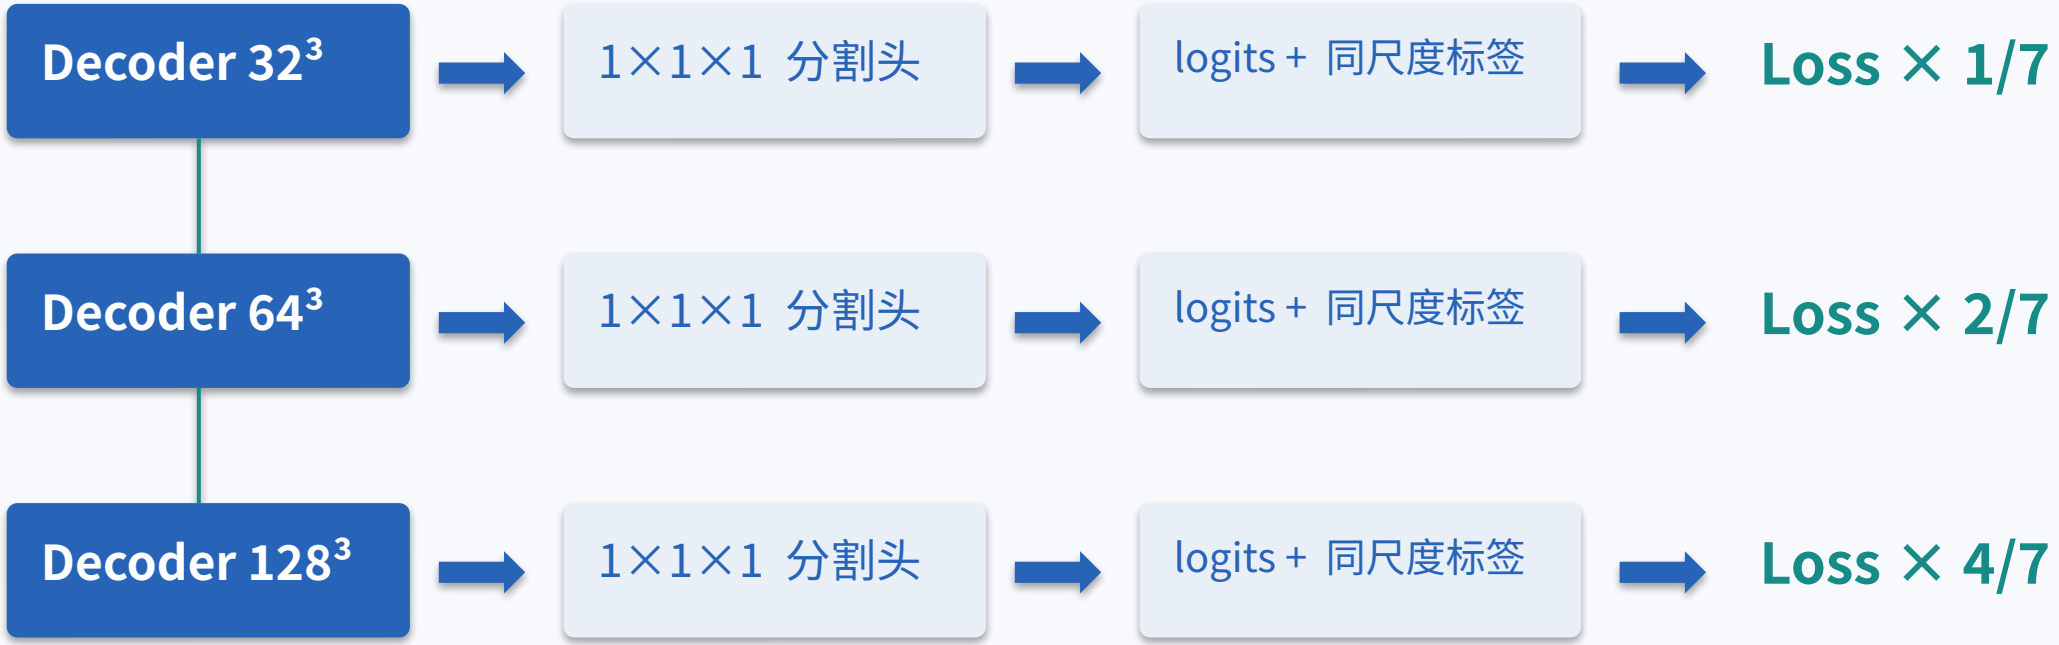
通常仍用标准 Trainer

不是预训练模型

残差连接：同一块内 Add； U-Net Skip： Encoder 到 Decoder 的 Concat 。

16 Decoder 多尺度预测与 Deep Supervision

成熟训练技术，并非 nnU-Net 首创；各尺度分割头输出逐体素 logits ，不是整幅影像分类。



总 Loss = Σ $w_s L_s$ ； 高分辨率权重更大。推理通常只使用最终全分辨率输出。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

17 配置一次训练：优化器、学习率与损失

标准基线将优化器、调度器、 Loss 和增强作为一套经过验证的训练方案。

SGD + Nesterov

$LR_0=0.01$

Momentum=0.99

Weight decay=3e−5

默认 1000 epochs

通常 250 训练迭代 /epoch

Poly LR

$lr(t)=lr_0(1-t/T)^{0.9}$

T=1000 时：

t=0： 0.01000

t=500： 0.00536

t=900： 0.00126

Loss 组合

互斥类别： Dice + CE

Region 任务： Dice + BCE

默认多类别 Dice 不计背景

多个尺度加权： Deep Supervision

负 Dice 项可使总 Loss 为负

AdamW 不是禁用选项；通过自定义 Trainer 实现，并重新匹配学习率与权重衰减。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

18 参数分层与推理

在线 Patch 验证监控优化；完整 Volume 验证才评估整个病例的分割结果。

train_step

取 Patch → 前向

Loss → 反向 → 更新

在线验证

采样 Patch

Pseudo Dice / EMA

完整验证

重叠滑窗

Gaussian 加权融合

空间恢复

恢复分辨率 / 裁剪

撤销转置 / 保存 NIfTI

记录可复现的实验状态

Plans 、 splits 、 Trainer 、软件版本、日志与权重。

评价最终模型

逐病例 / 逐器官指标、跨折统计、独立测试。

检查预测与原始影像能否正确叠加； Shape 一致并不自动意味着物理空间一致。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

19 配置一次训练：常用命令与参数

准确命令： nnUNetv2_plan_and_preprocess ； 本机支持选项以 -h 为准。

目的	参数	实际影响
首次准备 / 验证	-d 1 --verify_dataset_integrity	选择数据集并检查一致性
控制资源和处理范围	-c 3d_fullres -np 2 -npfp 4	预处理配置 / CPU 进程 / RAM 负载
仅检查规划 / 更新统计	--no_pp / --clean	跳过预处理 / 刷新 Fingerprint
架构预设 / 显存预算	-pl nnUNetPlannerResEncL / -gpu_memory_target	网络规划与 Patch 、 Batch
分辨率消融	-overwrite_target_spacing a b c	目标网格与后续资源开销
保留独立实验配置	-overwrite_plans_name MyPlans	训练、预测时用 -p MyPlans

Optimizer 、 LR 、 Loss 权重、 Epoch 、增强和前景比例通常通过自定义 Trainer 修改（训练用 -tr ）。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

20 实验网络真实配置

本页集中展示用户实验；其他页面介绍默认算法或教学示例。

维度	实际配置
数据	TotalSegmentator MRI； 23 例三器官子集； Fold 0： 18 训练 /5 验证
预处理	ZScoreNormalization； use_mask=False； Spacing [1.875,1.6016,1.4583]
网络输入	PlainConvUNet / 3d_fullres； Patch [96,128,192]； Batch 2
网络拓扑	6 级；卷积核均为 3^3；末级 stride=[1,2,2]
运行环境（用户记录）	Python 3.11； nnU-Net v2.8.1； CUDA 12.8； RTX PRO 6000
日志结果	Epoch 999 结束；完整体积 Mean Validation Dice = 0.92988

此结果不是五折均值或独立测试集成绩；模型配置与软件环境记录需随实验一同保存。

依据：用户两份训练日志与环境记录；最终验证均值仅对应 Fold 0 。

21 已完成工作总结与下一步计划

已梳理数据准备、预处理、规划与训练；下一步以同一划分完成验证和配置对比。

数据契约

几何一致

类别语义正确

规则规划

间距 / 网络 / Patch

匹配数据与预算

一致变换

图像与标签同步

强度与类别分开处理

可靠训练与评估

动态 Patch 与深监督

完整体积验证

① 统一 Spacing，不等于统一完整 Volume Shape。

② 非零裁剪、训练采样、增强输出裁剪，是不同操作。

③ 规划决定训练条件； Trainer 决定学习策略；验证检验最终效果。

参考： Isensee et al., Nature Methods 2021； nnU-Net Revisited 2024； 官方 nnunetv2 源码。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06。数值小例子均为教学示例。