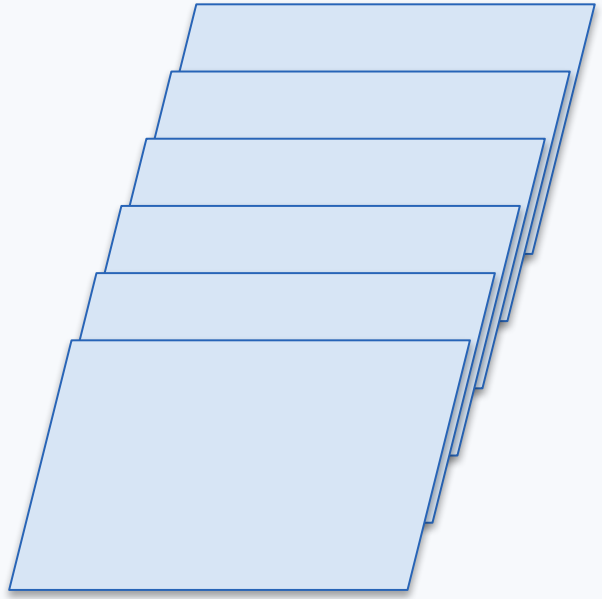
nnU-Net v2 | 三维医学影像分割

技术原理 · 自配置机制 · 三器官 MRI 实验

从空间采样到自动规划
从 Patch 训练到完整体积验证

Dataset102 · TotalSegmentator MRI

3d_fullres / PlainConvUNet / Fold 0



3D context

可编辑结构示意

汇报主线：数据几何 → 规则规划 → 训练机制 → 实验证据 → 后续验证

01 为什么需要自配置?

同一个 U-Net ，在不同数据上需要不同的空间尺度、训练视野和资源配置。

配置维度	传统手工 3D U-Net 流程	nnU-Net
预处理	人工设计裁剪、归一化与重采样	依据数据特征配置标准流程
训练视野	人工确定 Patch Size	结合体积统计与显存预算规划
网络拓扑	手动调整层数、卷积核与步幅	按间距与尺寸约束生成拓扑
训练 / 推理	自行组装采样、训练与预测	集成 Trainer 、滑窗和验证流程
模型选择	人工组织比较	用交叉验证比较配置 / 集成

核心： nnU-Net 是基于 U-Net 的自配置分割框架，不是一种全新的卷积网络。

来源： nnU-Net 官方文档；技术原理示意

02 完整 Pipeline：规划、学习与应用

训练前决定“怎么训练”；训练中学习权重；推理时复用预处理与模型配置。

训练前：规则驱动

Raw Dataset

影像、标签与元数据

Fingerprint

尺寸、间距与强度统计

Planning

目标间距、拓扑与预算

Preprocess

裁剪、归一化、重采样

Training

Patch 采样与参数学习

Validation

完整体积评估与配置选择

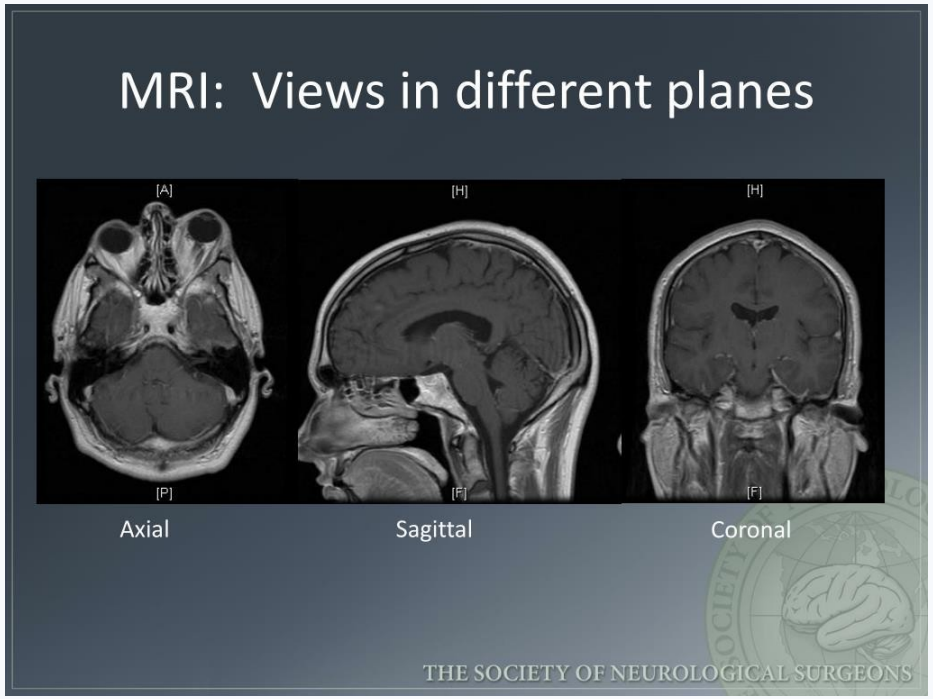
Inference

滑窗融合并还原空间

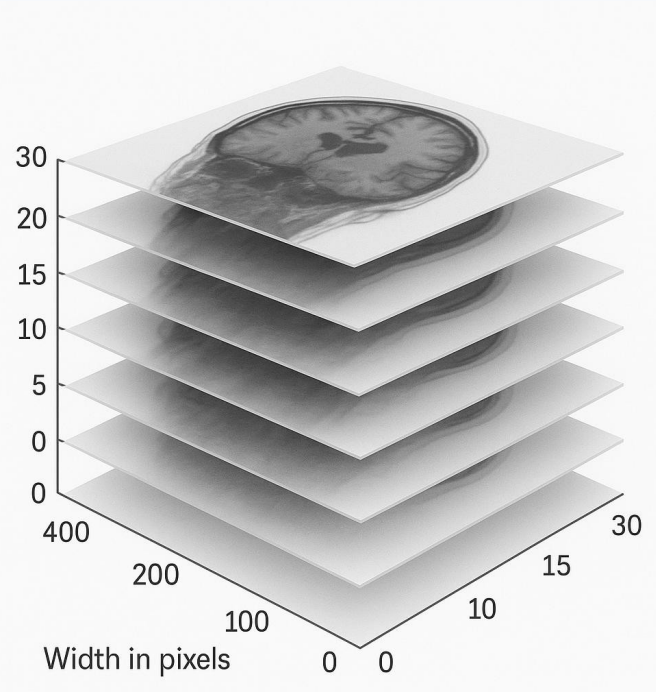
来源： nnU-Net 官方文档；技术原理示意

03 三维 MRI：多平面观察与切片堆叠

三个解剖平面帮助观察同一体积；切片间的物理距离由 Spacing 描述。



轴位 Axial · 矢状位 Sagittal · 冠状位 Coronal



堆叠图仅示意 Volume；图中刻度不作为测量依据。

Shape

512×512×54

Spacing (mm)

0.4688 / 0.4688 / 7

类型： int16

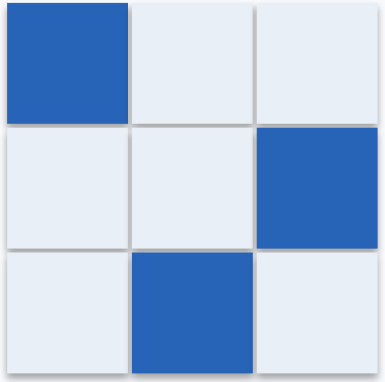
Affine： 体素坐标 → 世界坐标

右侧参数来自用户 MRI 病例，与脑部参考图无对应关系；数组轴序还需结合读取工具核对。

图片：用户仓库参考素材（adf54fe）；示例图不代表本实验病例或实际配置。

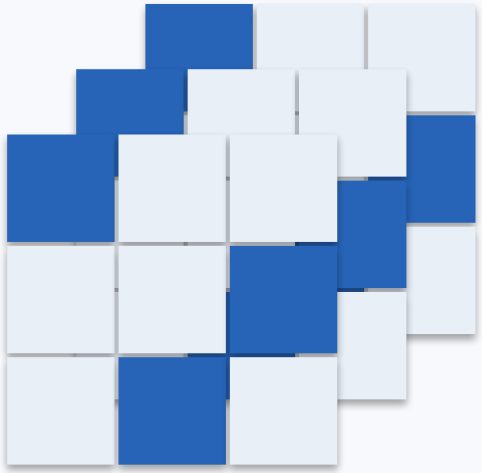
04 2D 与 3D 卷积：跨切片上下文从哪里来?

3D 卷积通过邻域聚合学习解剖连续性；不是简单地把切片逐张送入网络。



局部感受野

扩展至体积



2D： 3 × 3 核

仅在切片平面内聚合特征

3D： 3 × 3 × 3 核

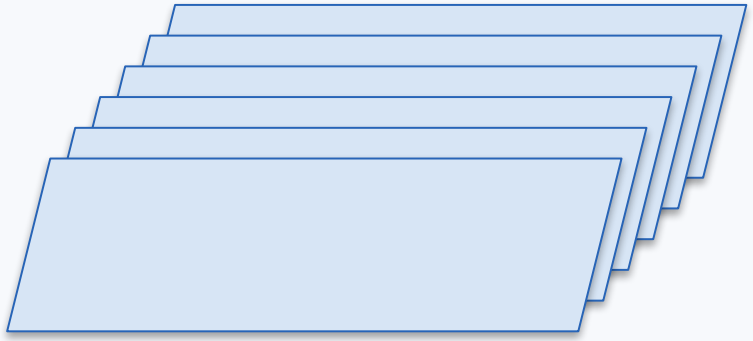
同时沿三个空间轴聚合特征

3D 卷积能够学习跨切片特征，但不能恢复扫描中从未采集的真实空间信息。

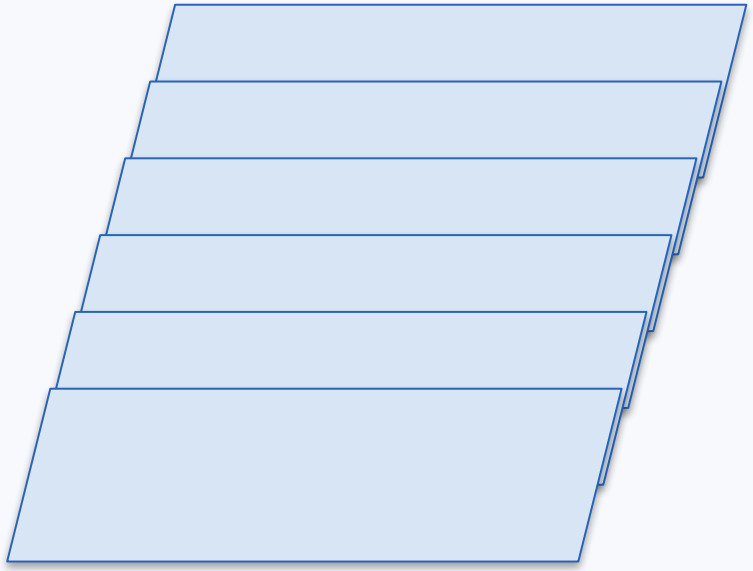
来源： nnU-Net 官方文档；技术原理示意

05 各向异性：一个“邻居”可能相隔很远

该病例 Z 方向采样间距约为 XY 的 15 倍，需要按物理尺度理解空间邻域。



薄层 / 近各向同性示意



厚层 / 各向异性示意

14.93×

相邻切片间距

7.0000 mm

平面内间距

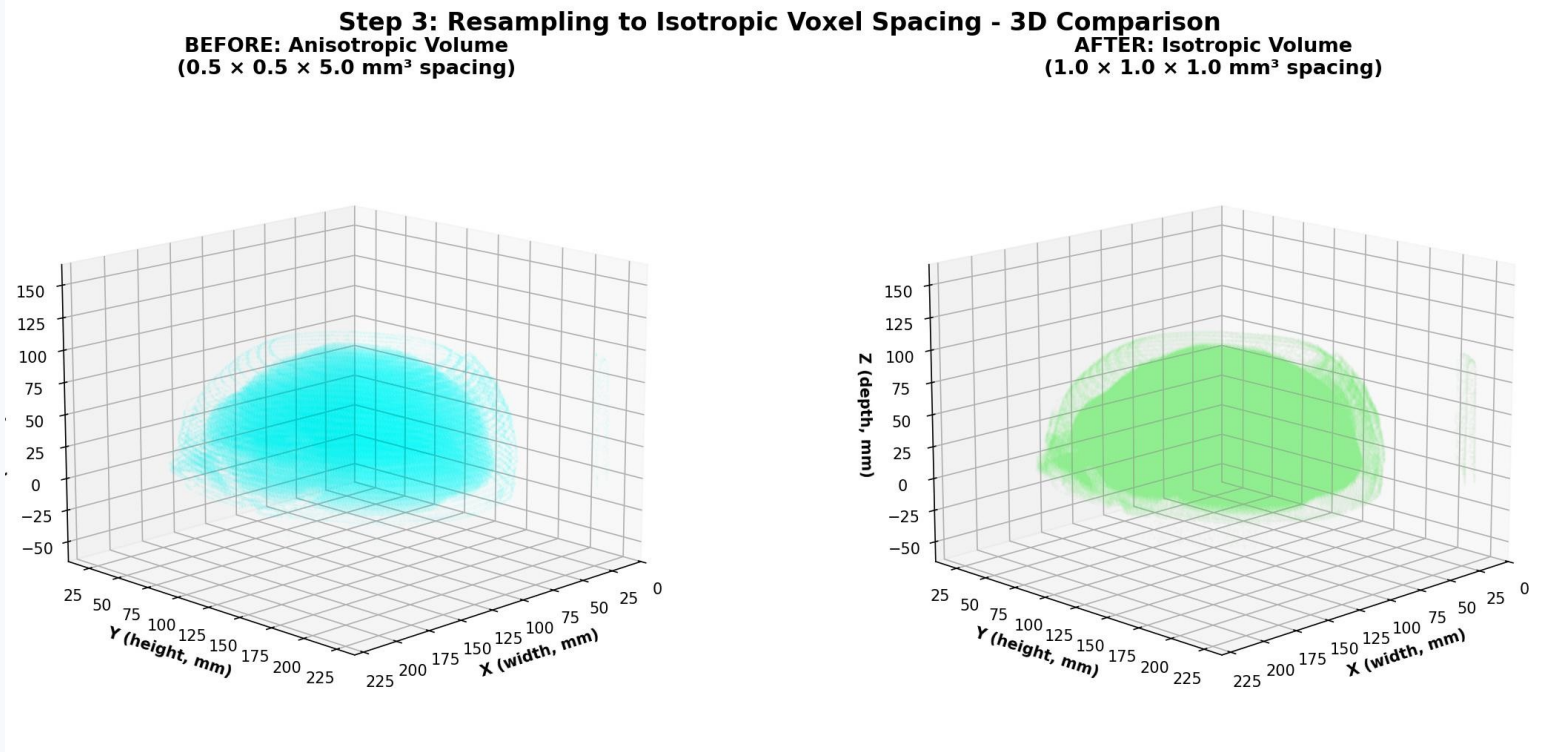
0.4688 mm

相同体素步幅 ≠ 相同物理步幅；重采样与网络拓扑需要共同适应数据。

来源：用户病例参数； 7 / 0.4688 = 14.9317

06 重采样：改变网格，不增加真实采集信息

图示说明各向异性 → 各向同性的概念； nnU-Net 的目标间距不一定各向同性。



Separate-Z

识别低分辨率轴

平面内与厚层轴分开处理

图像与标签分别插值

force_separate_z=None

表示按条件决定

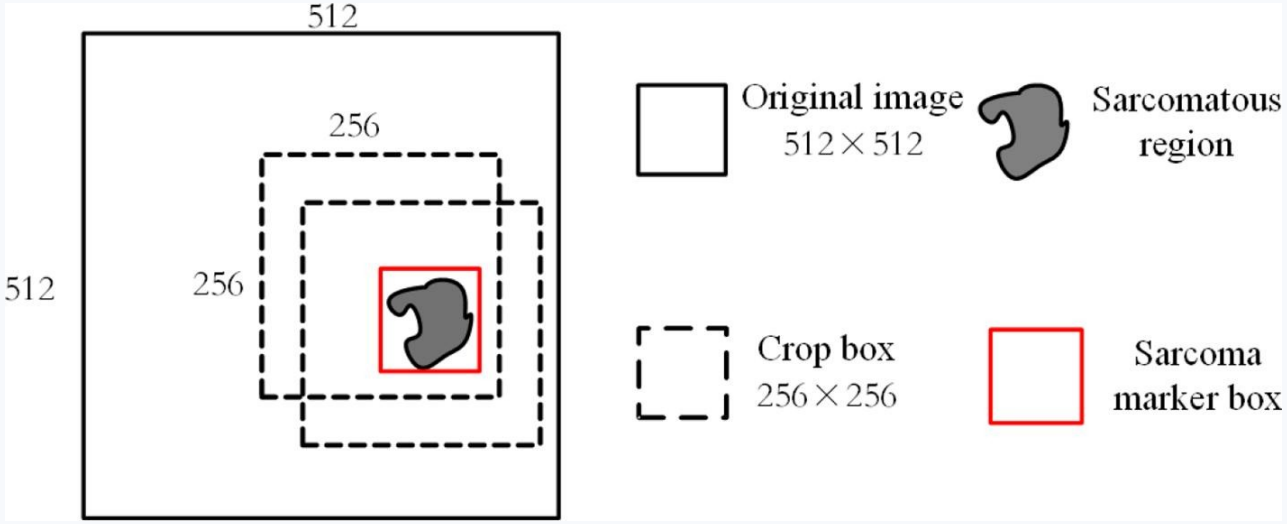
图示： 0.5×0.5×5 → 1×1×1 mm ； 本实验目标： [1.875, 1.6016, 1.4583] mm 。

本实验日志：图像 order=3 ； 标签 order=1 （按类别处理）； 两者 order_z=0 。

图片：用户仓库参考素材（ adf54fe ）；示例图不代表本实验病例或实际配置。

07 裁剪与采样：操作相似，发生阶段不同

左图用前景区域附近的裁剪框解释训练 Patch 采样，不代表 nnU-Net 非零区域裁剪。



原图为肿瘤示例， 512 / 256 是示例尺寸。

本实验目标为三器官， Patch 为 96×128×192 。

预处理： Cropping

依据非零区域包围盒，减少无效背景。

预处理： Normalization

Z-score ； 不使用归一化掩膜。

训练时：前景 Patch 采样

提高含目标 Patch 的采样比例。

非零区域裁剪 ≠ 标签引导的前景 Patch 采样；图像和标签需要保持空间对应。

图片：用户仓库参考素材（ adf54fe ）；示例图不代表本实验病例或实际配置。

08 Dataset Fingerprint → Experiment Planning

自动规划是规则驱动的训练前配置；不是在每次迭代中实时搜索超参数。

Fingerprint

Spacing / Shape

强度与前景统计

→

Target spacing

中位数等统计

兼顾各向异性

→

Patch / Topology

感受野与可整除性

最小特征图约束

→

Batch size

显存估算

数据规模约束

资源预算与网络约束共同调整 Patch 和 Batch

Plans 由整个规划数据集生成；本实验是 23 例子集，不能用单个病例解释全部配置。

来源： nnU-Net 官方文档；技术原理示意

09 真实 Plans：本次实验使用什么网络?

两份训练日志打印的配置一致： Dataset102 / 3d_fullres / PlainConvUNet 。

字段	实际配置
Target spacing (mm)	[1.875, 1.6016, 1.4583]
Patch / Batch	[96, 128, 192] / 2
Transpose forward	[0, 1, 2]
Stages / Features	6 / [32, 64, 128, 256, 320, 320]
Kernel sizes	6 个 Stage 均为 [3, 3, 3]

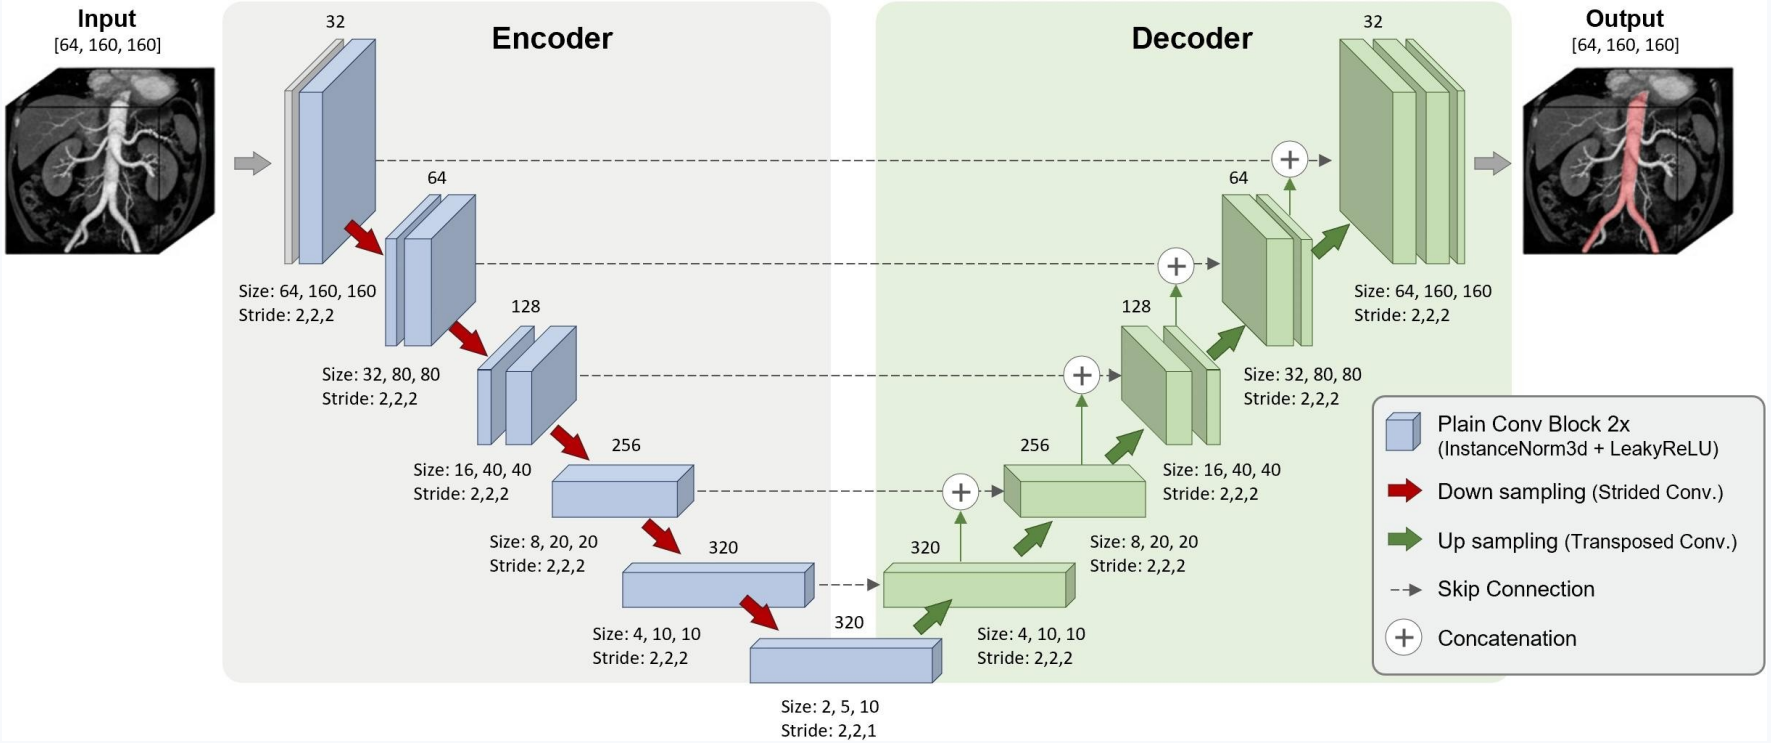
```
strides = [
  [1, 1, 1],
  [2, 2, 2],
  [2, 2, 2],
  [2, 2, 2],
  [2, 2, 2],
  [1, 2, 2]
]
```

空间维度按网络张量轴序表达；全部 3×3×3 卷积核说明该配置沿三个空间轴聚合特征。

来源：用户提供的两份训练日志（ 2026-11-03 / 11-04 ）

10 3D U-Net： 结构直观图与本实验真实尺寸

蓝色为 Encoder ，绿色为 Decoder ；跳跃连接拼接同尺度特征，恢复空间细节。



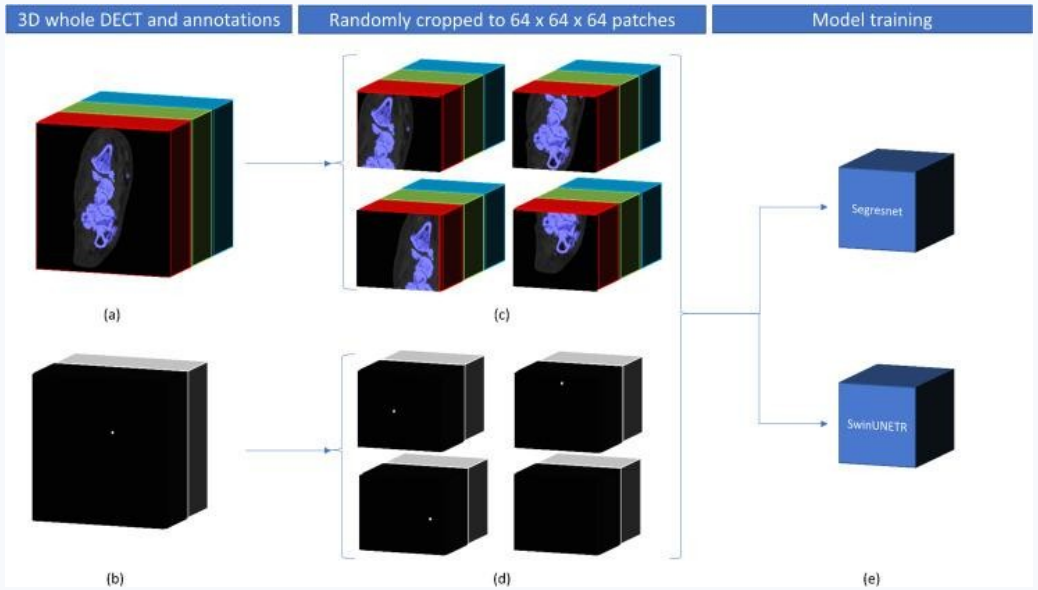
参考图尺寸与部分步幅标注不适用于本实验；实际六级空间尺寸以以下日志推导为准：

96×128×192 → 48×64×96 → 24×32×48 → 12×16×24 → 6×8×12 → 6×4×6

图片：用户仓库参考素材（ adf54fe ）；示例图不代表本实验病例或实际配置。

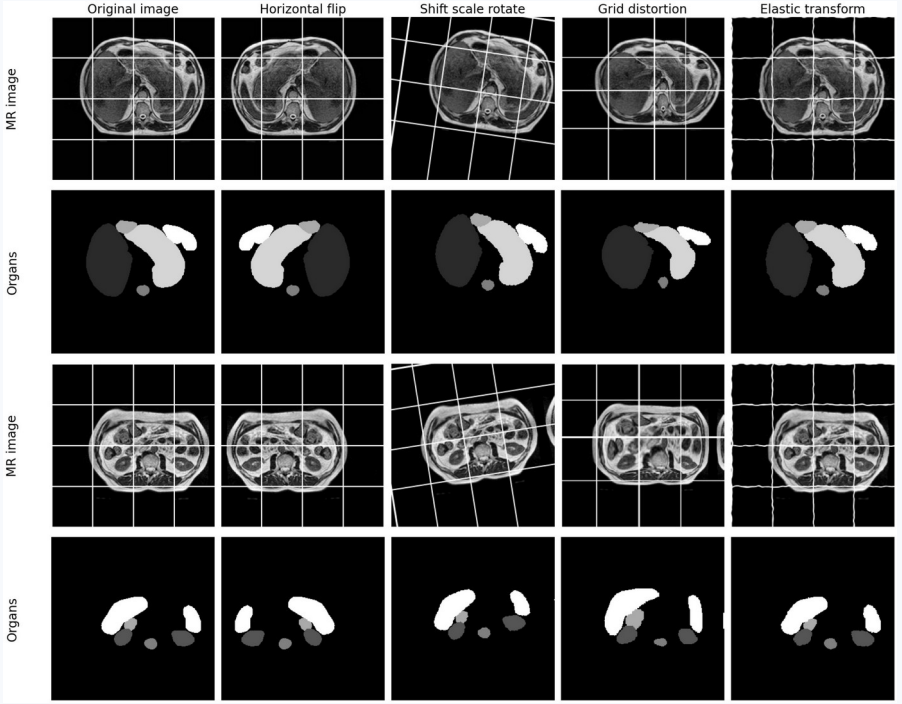
11 有效训练：三维 Patch 与图像—标签同步增强

训练视野由 Patch 决定；空间增强必须同时变换图像和标签，保持监督对应。



左图是 DECT 示例（64^3，其他网络）；

本实验： 96×128×192 → PlainConvUNet 。



右图为增强方法示例，并非本实验配置清单。

SGD + Momentum 0.99 | Poly LR | Dice + CE | Deep Supervision | Batch = 2

图片：用户仓库参考素材（ adf54fe ）；示例图不代表本实验病例或实际配置。

12 源码入口：配置怎样变成一次训练？

下图为关键逻辑调用链，省略多 GPU 启动包装； initialize 在训练开始钩子中按需执行。

CLI / entry

nnUNetv2_train

run_training_entry()

构造 Trainer

get_trainer_from_args()

读取 Plans / dataset.json

nnUNetTrainer

保存配置、 fold

实例化配置管理器

run_training()

on_train_start()

按需 initialize()

initialize()

创建网络、优化器

Loss 与深监督

epoch / train_step()

前向 → Loss → 反向

梯度更新与在线验证

来源：官方 nnunetv2/run/run_training.py 与 nnUNetTrainer.py （检索 2026-11-05 ）

13 参数分层与推理：哪些改动影响什么？

Plans 决定数据和网络； Trainer 定义学习策略； Runtime 选择本次运行对象。

参数层	关键内容	调整时的关注点
Plans	Spacing / Patch / Batch / Architecture	拓扑、数据预处理和显存预算
Trainer	LR / Epochs / Optimizer / Oversampling	学习策略与可复现的 Trainer 版本
Runtime	Dataset / Configuration / Fold / Device / --npz	--npz 保存验证概率供后续集成

```
CUDA_VISIBLE_DEVICES=0 nnUNetv2_train 102 3d_fullres 0 --npz
```

完整体积推理：重叠滑窗 → Gaussian 权重融合 → 可选镜像 / 模型集成 → 恢复原始网格

来源： nnU-Net 官方文档；技术原理示意

14 实验数据与环境：流程验证子集的定位

实验环境与原始数据统计由用户提供；日志确认 23 例子集及 Fold 0 的 18 / 5 划分。

TotalSegmentator MRI v2.0.0

616 例 MRI：训练 561 / 测试 55

50 类器官 Mask； NIfTI .nii.gz

当前子集： 23 例，三器官

0 Background · 1 Liver

2 Spleen · 3 Left Kidney

远程 GPU 实验环境

Linux + VS Code Remote-SSH

Miniforge / Conda · Python 3.11

nnU-Net v2.8.1 （用户记录）

PyTorch CUDA 12.8

NVIDIA RTX PRO 6000 Blackwell

23 例用于验证工程流程与小样本基线；不是对全部 561 例训练数据的性能结论。

来源：用户实验说明；训练日志验证 Dataset102 与划分信息

15 数据转换与质控：从独立 Mask 到多类别标签

先验证几何一致性，再合并语义；保留原始数据与冲突记录，保证可追溯。

读取

MRI + Liver

Spleen + Left kidney

→

几何检查

Shape / Spacing

Affine / 方向

→

语义检查

前景计数、标签值

跨器官重叠

→

合并导出

0 / 1 / 2 / 3

生成 nnUNet_raw

```
Dataset102_TotalSegMRI3Organs/
  imagesTr/s0009_0000.nii.gz
  labelsTr/s0009.nii.gz
  dataset.json
```

s0009： 5 个冲突体素

脾脏 ∩ 左肾，约 0.0612%

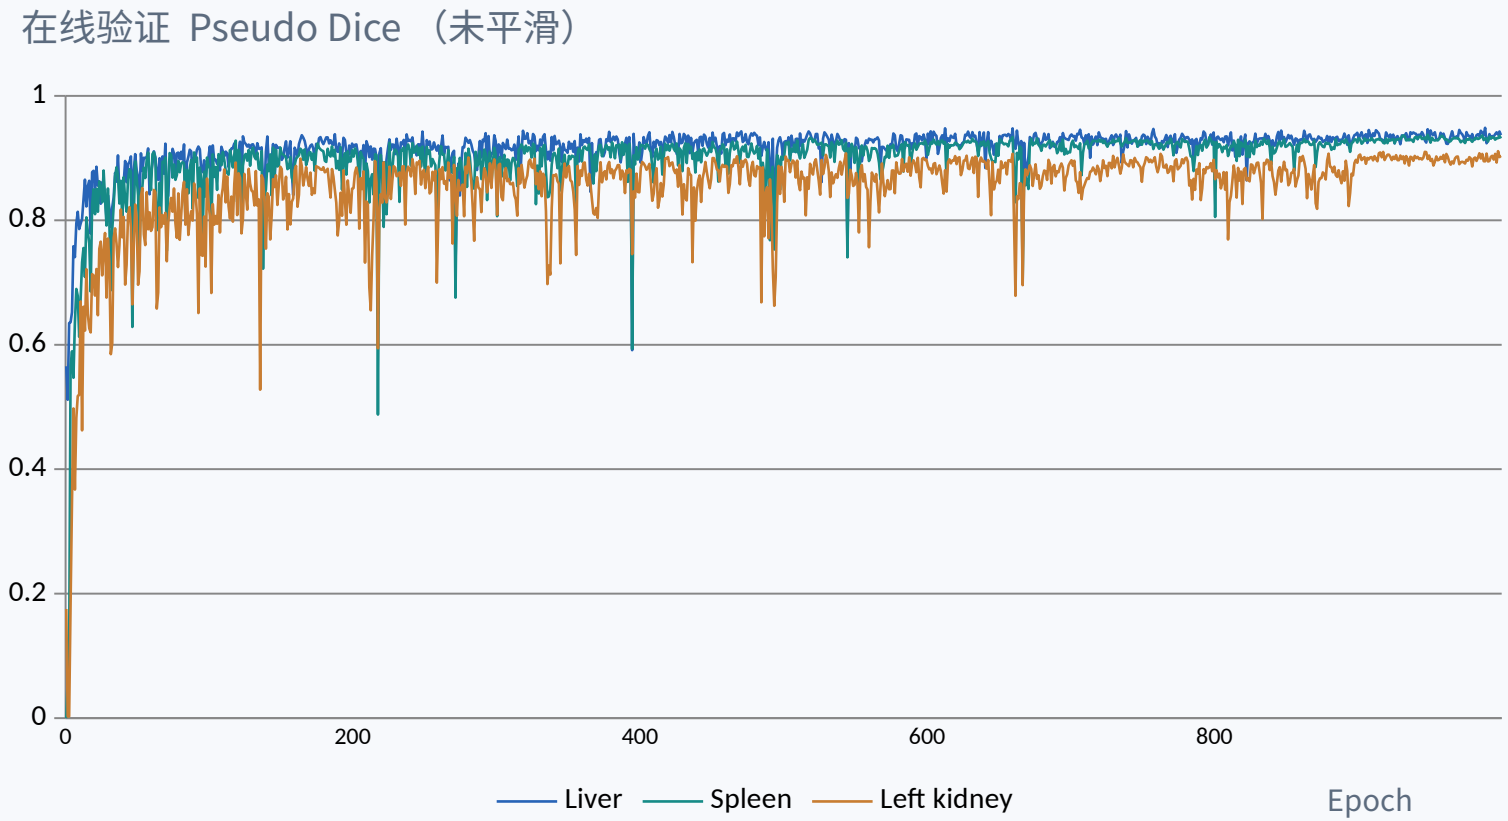
当前策略：冲突设为背景，原始数据保留

将重叠置为背景是工程策略，并不意味着医学上真实背景；扩展实验前应复核标签。

来源：用户数据转换记录；重叠比例口径为相对于较小器官

16 真实训练曲线： Fold 0 已完成训练与验证

两份日志存在重复 Epoch； 450 起采用 11 月 4 日记录，避免把重跑区间重复计算。



日志已确认

Fold 0： 18 train / 5 val

Epoch 999 完成

最终在线 Pseudo Dice

0.9369 / 0.9316 / 0.9035

最佳 EMA： 0.9232

Pseudo Dice 来自训练中的采样 Patch；它是监控信号，不应当作独立测试集分割结果。

来源：用户提供的两份训练日志（2026-11-03 / 11-04）

17 如何解读 0.92988： 证据范围与下一步

日志完成 5 个验证病例的完整体积预测，并输出 Mean Validation Dice 。

0.92988

Fold 0 · Mean Validation Dice

5 例完整体积验证

验证病例： s0007 / s0014 / s0018

s0030 / s0033

可以确认 / 仍需补齐

✓ 训练结束， Validation complete

✓ 当前划分下流程能完成预测与评估

待补：逐病例、逐器官 summary.json

待补：其余 4 折及独立测试集

待补：误差条与分割可视化

不将单折验证均值解释为五折均值、官方测试集成绩或临床泛化能力。

来源：用户提供的两份训练日志（2026-11-03 / 11-04）

18 近期进展：更强的基线与更严格的比较

选择与当前项目直接相关的已核实进展；不把更大模型的收益视为本实验既成结论。

v2：模块化与可扩展

Planner / Trainer / 网络解耦

配置与训练代码便于定制

沿用完整分割 pipeline

重点仍是系统配置与验证

ResEnc：残差编码器

官方提供 M / L / XL 预设

面向不同显存与计算预算

官方文档推荐 ResEnc L

本实验仍是 PlainConvUNet

严谨评测优先

统一数据划分与训练预算

报告跨折、逐器官结果

比较收益与计算成本

本项目下一候选： ResEnc L

建议对照： PlainConvUNet vs ResEnc ，保持数据划分一致；先建立可靠基线，再扩大模型。

来源： nnU-Net 官方 ResEnc presets 文档； Isensee et al., nnU-Net Revisited (2024), arXiv:2404.09556

19 工作路线图与总结

工程流程已推进到单折训练与完整体积验证；下一阶段重点是评估完整性与可解释的比较。

已完成：环境与数据

远程 GPU / Conda

BTCV 尺寸不一致排查

已完成：流程闭环

切换 MRI / Mask 合并

Dataset102 / 规划预处理

已完成：单折基线

Fold 0 训练完成

5 例完整体积验证

下一步：可靠评估

其余四折 / 独立测试

三维可视化 / 配置对比

01 nnU-Net 的价值：自动配置从数据到推理的完整分割流程。

02 三维分割的关键：空间几何、各向异性与足够的上下文。

03 当前证据： 23 例子集单折可运行；泛化结论仍需完整评估。

主要参考： Isensee et al., Nature Methods 2021； nnU-Net Revisited 2024； nnU-Net 官方源码与文档。

来源：用户工作记录与两份训练日志；参考链接见本页备注与随附资料