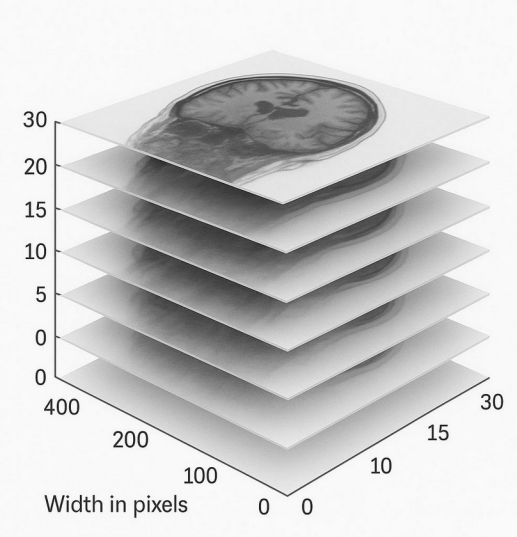
nnU-Net v2 | 从数据准备到模型训练

数据几何 · 强度处理 · 自动规划 · Patch 采样 · 多尺度监督

理解每一次数据变换
以及它为什么影响训练



数据

几何与标签一致

规划

确定空间视野

预处理

统一表达

训练

局部采样与优化

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

01 完整流程：哪些在训练前，哪些在训练中？

Fingerprint 负责统计； Planner 决定配置； Preprocessor 执行变换； Trainer 学习权重。

准备数据

影像 / 标签

dataset.json

Fingerprint

Spacing / Shape

强度统计

Plans

间距 / Patch

拓扑 / Batch

Preprocess

转置 / 裁剪

归一化 / 重采样

动态取 Patch

随机 / 前景引导

增强与训练

空间变换 / Loss / 更新

完整验证

滑窗 / 空间恢复 / 指标

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

02 数据准备：先建立正确的空间与标签契约

文件尺寸一致只是必要检查之一；还必须检查方向、间距、位置与类别语义。

```
Dataset001_Example/
  imagesTr/case001_0000.nii.gz
  imagesTr/case001_0001.nii.gz
  labelsTr/case001.nii.gz
  dataset.json
```

_0000 、 _0001 表示输入通道。

channel_names 决定默认归一化映射。

准备阶段的四项检查

几何： Shape / Spacing / Affine

多通道：同一病例各序列已经对齐

标签：整数类别、背景 0 、无非法值

划分：同一患者不跨训练 / 验证集

框架不会通过 resize 自动修复错位，也不会可靠地从影像内容猜测 CT / MRI 模态。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

03 Image 、标签 Mask 、有效区 Mask 是三种对象

“Mask” 不是唯一一种数据；不同对象决定了哪些操作允许执行。

对象	数值含义	允许的处理
Image	连续影像强度	强度归一化、连续插值、强度增强
分割标签	0 背景； 1 、 2 、 3 为不同类别	同步空间变换；标签专用插值；不做 Z-score
有效区 Mask	True / False ： 有效影像区域	控制裁剪或归一化统计范围

同一空间变换

图像与标签同步

不同数值处理

图像强度 ≠ 类别编号

恢复原始空间

保存裁剪与坐标属性

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

04 Fingerprint： 统计数据集，不提前训练网络

默认分析原始间距、非零裁剪后尺寸、裁剪比例与前景强度等；此处不执行目标网格重采样。

各病例读取

Spacing

Shape

有效区裁剪统计

shapes_after_crop

裁剪体积比例

前景强度采样

每通道均值 / 标准差

分位数

数据集摘要

dataset_fingerprint.json

几何统计 → 网络规划

决定目标间距、典型尺寸与训练视野。

强度统计 → 归一化

CT 使用训练集前景统计； MRI 常逐病例计算。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

05 Target Spacing： 先逐轴中位数，再检查各向异性

每一列独立计算统计量；目标间距不必来自某一个病例，也不要求变成 1×1×1 mm 。

病例	轴 0 (mm)	轴 1 (mm)	轴 2 (mm)
A	1	1	3
B	1	1	5
C	1	1	7
D	1	1	9
E	1	1	11
中位数	1	1	7

厚层轴调整示例

中位 Shape = [256,256,40]

7 > 3×1 ， 且 40×3 < 256

两条件满足 → 该轴取 10% 分位数

[3,5,7,9,11] → P10 = 3.8

目标间距： [1,1,3.8] mm

这是 Planner 的间距规则；执行重采样时是否分轴，还要由重采样器判断。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

06 重采样后的 Shape：保持物理范围，改变网格密度

各病例共享目标 Spacing，但预处理后的完整 Volume Shape 仍然可以不同。

$$N_{new}[i] = \mathrm{round}(N_{crop}[i] \times S_{old}[i] / S_{target}[i])$$

裁剪后原始数据

Shape [20,256,256]

Spacing [5,1,1]

→

指定目标间距

[2.5,0.5,0.5] mm

三个方向采样均加密

→

目标数组

Shape [40,512,512]

体素总数增加 8 倍

Shape 与 Spacing 必须采用相同轴序；插值新增体素，不增加真正采集到的医学信息。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

07 Separate-Z： 先平面，再低分辨率轴

不是先做一次完整 XYZ 重采样，再重复处理 Z； Z 表示低分辨率轴，不固定对应数组第三轴。

原数组

[20,256,256]

低分辨率轴长度 20

平面内插值

[20,512,512]

每层二维插值，层数不变

低分辨率轴插值

[40,512,512]

仅改变第一轴长度

分轴路径

平面内用 order；低分辨率轴用 order_z 。

非分轴路径

直接整体空间插值；此时 order_z 不参与。

force_separate_z=None： 根据原始 / 目标间距与轴唯一性判断，不是每个病例都强制分轴。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

08 插值阶数与标签专用路径

order 控制插值阶数；它不是训练超参数，也不是卷积核大小。

order	方法	一维教学例子
0	最近邻	x=0 强度 10 ， x=1 强度 20 ； x=0.25 → 10
1	线性插值	x=0.25 → 0.75×10 + 0.25×20 = 12.5
3	三次插值	利用更大邻域；结果还取决于边界约定

```
image: is_seg=False, order=3
label: is_seg=True,  order=1
Separate-Z: order_z=0
```

标签 [1,3] 不能平均成类别 2

按类别二值图插值，再重建离散标签。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

09 CT 与 MRI：差异主要在强度归一化

方案由通道元数据及规划规则确定；不是根据验证成绩动态搜索归一化方法。

维度	CTNormalization	MRI 常用 ZScoreNormalization
强度基础	HU 通常具有可比较的物理意义	绝对强度随设备、序列、扫描变化
统计范围	整个训练数据集的前景强度样本	当前病例、当前输入通道
强度截断	前景 0.5% ～ 99.5% 分位数	默认不使用同一套 CT 截断
归一化	统一训练集 mean / std	每病例 mean / std
推理	复用训练集统计，无需真值标签	对新病例计算其自身统计

默认流程不自动加入 MRI 偏置场校正或直方图匹配；有效区 Mask 与器官真值 Mask 不同。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

10 Z-score 与非零裁剪：统计区域必须说清楚

默认顺序： Transpose → Crop → Normalize → Resample ； 归一化不会改变体素坐标。

Z-score 的数值例子

强度： [10,20,30,40]

$\mu=25$ ； $\sigma=\sqrt{125}\approx11.1803$

$z=(x-\mu)/\max(\sigma,\varepsilon)$

结果： [-1.342,-0.447,0.447,1.342]

不使用 Mask 时，背景零值也参与统计。

裁剪 Bounding Box 例子

原 Shape： [10,12,8]

有效索引： 2 ～ 7 / 3 ～ 9 / 1 ～ 5

bbox = [[2,8],[3,10],[1,6]]

裁剪： image[2:8,3:10,1:6]

新 Shape： [6,7,5] ； 标签使用同一框。

多通道非零区域取并集并填孔；填的是有效区掩膜，不是把原始影像的零强度改成 1 。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

11 Patch 与网络共同规划：空间视野必须放得进显存

显存目标是估算预算，不是当前 GPU 剩余显存的实时测量。

典型数据尺度

目标 Spacing

重采样后中位 Shape

初始 Patch / 拓扑

物理视野

卷积核 / 下采样

估算资源开销

各级特征图

显存预算

调整并生成 Plans

Patch 可整除性

最小特征图 / Batch

各向异性可能影响早期拓扑

例如 kernel=[1,3,3] 、 stride=[1,2,2] 。

尺度逐渐接近后使用完整 3D 操作

空间尺寸过小时停止相应轴的下采样。

Patch 大小由 Plans 决定；每次训练只动态改变位置，不按当前器官大小临时改变网络输入。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

12 Foreground Sampling： 先决定样本类型，再选位置

默认确定性模式按 Batch 内的样本索引分配；不是每次独立以 33% 概率抛硬币。

```
threshold = round(B * (1 - p))
force_fg = sample_index >= threshold
```

B=2 ， p=0.33	索引 0	索引 1
threshold=1	普通随机	强制前景

前景引导路径

先选病例

从现有前景类别中选类别

从该类候选坐标中选一个体素

围绕该体素构造采样框

无可用前景时可退回随机

普通随机 Patch 也可能有器官；强制前景采样比例不等于最终“含前景 Patch” 的比例。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

13 Patch Bounding Box： 固定大小，动态起点

以下示例采用当前官方上下界约束逻辑，无额外增强 Padding；旧版本右边界处理可能不同。

```
N = [100,120,80]
P = [40,40,32]
allowed_start = [0,0,0] ... [60,80,48]
start = clip(v - P//2, lb, ub)
end = start + P
```

前景坐标 v	起点 start	终点 end
[50,70,30]	[30,50,14]	[70,90,46]
[5,10,4]	[0,0,0]	[40,40,32]
[95,115,75]	[60,80,48]	[100,120,80]

随机采样：从每个轴允许的起点区间抽整数。

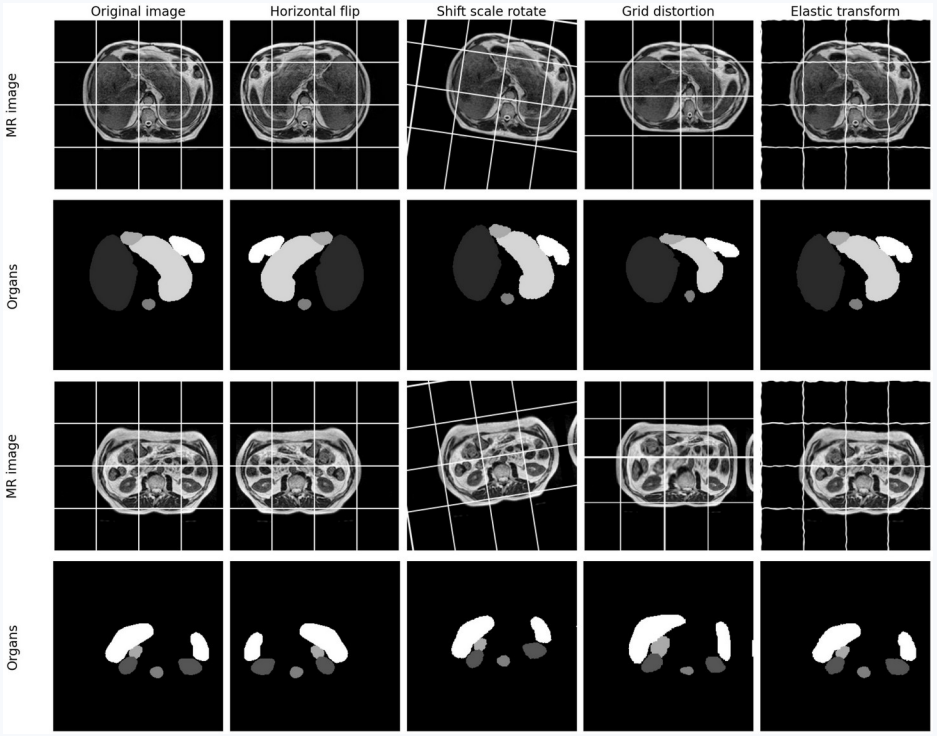
病例小于 Patch： 先取框与影像的交集，再对缺失区域显式 Padding。

1D 例：病例长 24、 Patch 长 32 → 有效数据 24 + 两侧各补 4；不能用负索引切片替代 Padding。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06。数值小例子均为教学示例。

14 裁剪与增强顺序：先取大块，再生成最终 Patch

扩大初始采样块提供变换所需的上下文，但不保证完整器官始终留在最终视野。



两种尺寸不要混淆

initial_patch_size： 增强前取样尺寸

patch_size： 最终网络输入尺寸

例： 128^2 旋转 45° 的包围框约 181^2

实际由旋转 / 缩放范围共同估计

空间变换同步作用于图像和标签

P_load 较大初始块 → **空间变换** 旋转 / 缩放 → **P_final** 固定网络输入

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

15 从普通 U-Net 到 ResEnc L：改变架构，也改变规划预算

ResEnc L 是残差编码器 U-Net 的规划预设，不是固定 Patch 的单一网络，也不是预训练模型。

残差块内部

F(x) + S(x)

特征相加 Add

U-Net 跨层连接

Encoder → Decoder

通道拼接 Concat

ResEnc L Planner

约 24GB 级别预算

重估 Patch / Batch

主要改动在 Encoder

残差捷径有助于优化； Decoder 仍做上采样与拼接。

训练方案通常继续使用标准 Trainer

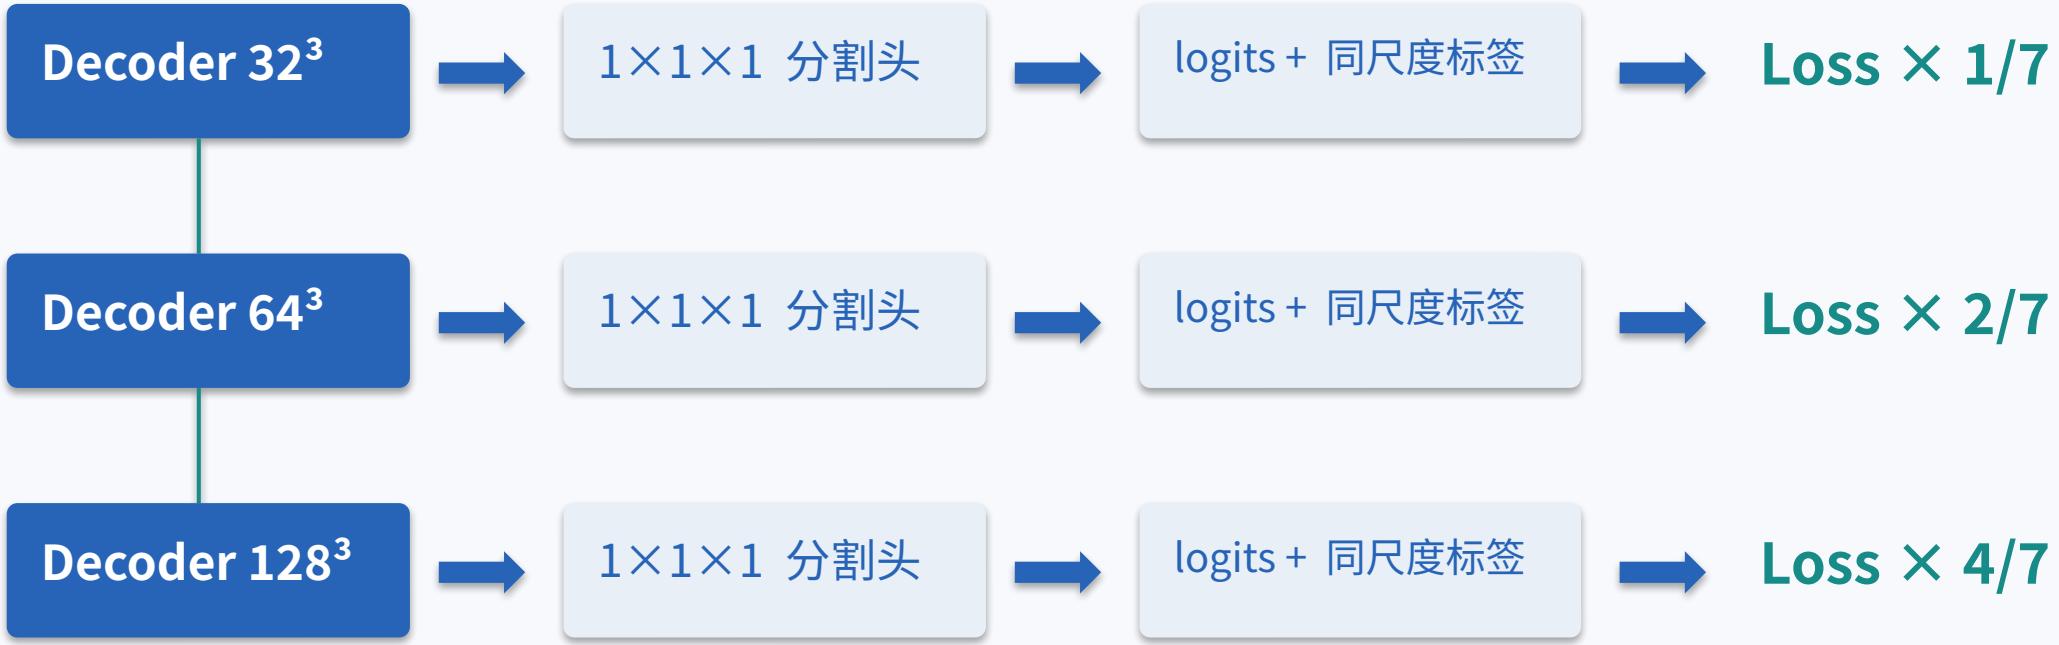
SGD 、 Poly LR 、 Dice 组合损失与深监督仍保留。

比较标准 U-Net 与 ResEnc L ，是比较完整配置；不能把所有收益都归因于残差连接。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

16 Deep Supervision： 中间 Decoder 也接受分割监督

成熟训练技术，并非 nnU-Net 首创；各尺度分割头输出逐体素 logits ，不是整幅影像分类。



总 Loss = $\Sigma\, w_s L_s$ ； 高分辨率权重更大。推理通常只使用最终全分辨率输出。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

17 训练配方：优化器由 Trainer 定义，不由 Planner 搜索

标准基线将优化器、调度器、 Loss 和增强作为一套经过验证的训练方案。

SGD + Nesterov

$LR_0=0.01$

Momentum=0.99

Weight decay=3e−5

默认 1000 epochs

通常 250 训练迭代 /epoch

Poly LR

$lr(t)=lr_0(1-t/T)^{0.9}$

T=1000 时：

t=0： 0.01000

t=500： 0.00536

t=900： 0.00126

Loss 组合

互斥类别： Dice + CE

Region 任务： Dice + BCE

默认多类别 Dice 不计背景

多个尺度加权： Deep Supervision

负 Dice 项可使总 Loss 为负

AdamW 不是禁用选项；通过自定义 Trainer 实现，并重新匹配学习率与权重衰减。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

18 从训练步到完整体积验证：两类指标不要混用

在线 Patch 验证监控优化；完整 Volume 验证才评估整个病例的分割结果。

train_step

取 Patch → 前向

Loss → 反向 → 更新

在线验证

采样 Patch

Pseudo Dice / EMA

完整验证

重叠滑窗

Gaussian 加权融合

空间恢复

恢复分辨率 / 裁剪

撤销转置 / 保存 NIfTI

记录可复现的实验状态

Plans 、 splits 、 Trainer 、软件版本、日志与权重。

评价最终模型

逐病例 / 逐器官指标、跨折统计、独立测试。

检查预测与原始影像能否正确叠加； Shape 一致并不自动意味着物理空间一致。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

19 CLI： 优先修改有明确实验目的的参数

准确命令： nnUNetv2_plan_and_preprocess ； 本机支持选项以 -h 为准。

目的	参数	实际影响
首次准备 / 验证	-d 1 --verify_dataset_integrity	选择数据集并检查一致性
控制资源和处理范围	-c 3d_fullres -np 2 -npfp 4	预处理配置 / CPU 进程 / RAM 负载
仅检查规划 / 更新统计	--no_pp / --clean	跳过预处理 / 刷新 Fingerprint
架构预设 / 显存预算	-pl nnUNetPlannerResEncL / -gpu_memory_target	网络规划与 Patch 、 Batch
分辨率消融	-overwrite_target_spacing a b c	目标网格与后续资源开销
保留独立实验配置	-overwrite_plans_name MyPlans	训练、预测时用 -p MyPlans

Optimizer 、 LR 、 Loss 权重、 Epoch 、增强和前景比例通常通过自定义 Trainer 修改（训练用 -tr ）。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06 。数值小例子均为教学示例。

20 实验配置示例：将上述机制映射到一个实际任务

本页集中展示用户实验；其他页面介绍默认算法或教学示例。

维度	实际配置
数据	TotalSegmentator MRI； 23 例三器官子集； Fold 0： 18 训练 /5 验证
预处理	ZScoreNormalization； use_mask=False； Spacing [1.875,1.6016,1.4583]
网络输入	PlainConvUNet / 3d_fullres； Patch [96,128,192]； Batch 2
网络拓扑	6 级；卷积核均为 3^3；末级 stride=[1,2,2]
运行环境（用户记录）	Python 3.11； nnU-Net v2.8.1； CUDA 12.8； RTX PRO 6000
日志结果	Epoch 999 结束；完整体积 Mean Validation Dice = 0.92988

此结果不是五折均值或独立测试集成绩；模型配置与软件环境记录需随实验一同保存。

依据：用户两份训练日志与环境记录；最终验证均值仅对应 Fold 0 。

21 总结：一条可解释、可复现的数据—训练链路

理解每一步的输入、输出和责任边界，才能判断改动是否合理。

数据契约

几何一致

类别语义正确

规则规划

间距 / 网络 / Patch

匹配数据与预算

一致变换

图像与标签同步

强度与类别分开处理

可靠训练与评估

动态 Patch 与深监督

完整体积验证

① 统一 Spacing，不等于统一完整 Volume Shape。

② 非零裁剪、训练采样、增强输出裁剪，是不同操作。

③ 规划决定训练条件； Trainer 决定学习策略；验证检验最终效果。

参考： Isensee et al., Nature Methods 2021； nnU-Net Revisited 2024；官方 nnunetv2 源码。

依据： nnU-Net v2 默认实现；官方源码核对 2026-11-06。数值小例子均为教学示例。